

HateXplain 중간발표

Q&A 답변 카드

올에이프로젝트 | 7분반

정수현 · 김정훈 · 박종화 · 조은 · 차종민

핵심 메시지

"단어 단서뿐 아니라 맥락 단서까지 함께 학습한 모델"이
베이스 대비 분류 성능과 판단 투명성 모두 향상됨을 정량 입증

목차

- P0. 가장 자주 나올 질문 (필수)
- P1. 모델·방법론
- P2. 데이터·실험 설계
- P3. XAI 분석
- P4. 서술·해석·논리
- P5. 기술 디테일
- P6. 비교·차별점
- 부록. 숫자 치트시트

P0. 가장 자주 나올 질문 (필수)

Q. 왜 BERT가 RoBERTa보다 성능이 좋게 나왔나요? 일반적으로는 RoBERTa가 더 좋다고 알려져 있지 않나요?

맞습니다. GLUE/SuperGLUE 같은 일반 NLU 벤치마크에서는 RoBERTa가 평균적으로 우세합니다.

다만 본 실험은 HateXplain ($\approx 19K$) 의 작은 도메인 데이터에 짧은 SNS 텍스트입니다.

RoBERTa는 BPE 기반 서브워드(접두)로 슬러를 더 잘게 쪼개는 경향이 있고, 학습 데이터 분포(book corpus 중심)가 SNS 비속어 분포와 다소 어긋납니다.

BERT WordPiece(##)는 슬러 통째 토큰을 더 자주 보존해 약한 단어 신호를 잡기 유리했고, 결과적으로 8조건 평균 BERT 패밀리가 ≈ 0.01 F1 우세였습니다.

핵심: 작은 SNS 도메인 + 슬러 보존성 차이로 BERT가 약간 유리. 일반 결론이 아니라 본 데이터셋 한정 결과.

주의: "BERT가 무조건 더 좋다"고 일반화하지 말 것. 도메인/데이터 크기 의존.

Q. Plausibility 22% 향상 — 인간 합의도(IAA)는 얼마인가요?

저희가 직접 계산한 Rationale IAA(annotator 간 합의)는 0.31 입니다.

11,412 샘플 $\times$ 27,213 leave-one-out 토큰 비교로 산출 (annotator 한 명을 빼고 나머지가 합치 보는 방식).

이 0.31이 "인간 사이의 자연 상한" 역할을 합니다. 즉 인간끼리도 토큰 단위 근거 표시는 0.31 정도밖에 안 맞음.

베이스 A_B의 Token F1 $\approx 0.18 \rightarrow$ 개선 D_B ≈ 0.22 (+22%). 인간 상한 0.31에 더 가까워졌다는 의미.

핵심: 22%는 인간 상한 0.31을 향한 접근율. "인간 수준 도달"이 아니라 "근거 일치도가 인간 합의에 더 가까워졌다".

주의: 22%를 "인간보다 잘함"으로 오해하면 안 됨. 여전히 $0.22 < 0.31$.

Q. Slur-Free 케이스에서 0% — 결국 욕설 없으면 못 잡는 거 아닌가요?

맞습니다. 솔직히 말씀드리면, 명시적 슬러가 0개인 문장에서는 베이스/개선 모두 분류 정확도가 0에 수렴했습니다.

이것이 본 실험의 가장 큰 한계이자 다음 단계의 출발점입니다.

다만 슬러 1개 이상 포함 케이스에서는 D_B가 A_B 대비 명확히 일관된 개선을 보였습니다 — 즉 Attention Loss + VADER 처치는 "단어 신호가 있는 상황에서 맥락 단서를 추가로 활용"하는 방향으로 작동.

암시적 혐오(implicit hate, dog-whistle)는 본 데이터셋의 학습 분포 자체가 슬러 중심이라 사전 학습으로는 한계가 있고, 이는 추후 implicit hate 데이터셋 추가가 필요한 영역입니다.

핵심: 암시적 혐오는 미해결. 그러나 슬러 포함 케이스에서는 처치 효과가 일관됨.

주의: 이 한계는 숨기지 말고 그대로 인정 — 솔직함이 신뢰 점수.

Q. ANOVA p-value가 모두 0.05를 넘어서 통계적 유의성이 없다고 봤는데, 그러면 결론을 내릴 수 있나요?

p-value가 큰 것은 "차이가 없다"가 아니라 "현재 데이터(시드 n=3)로는 차이를 통계적으로 확증할 검정력이 부족하다"는 뜻입니다.

동일 비교의 Cohen's d는 |1.91|로 Cohen 기준 'very large' 구간 — 효과 크기 자체는 큼니다.

즉 "효과는 일관되게 크지만 시드 수 부족으로 ANOVA 임계점은 못 넘김" 상태입니다.

추후 시드 10개 이상으로 검정력 보강이 향후 과제입니다. 현재는 효과 크기 + 일관된 방향성으로 결론을 보고하고 있고, 이는 absence of evidence ≠ evidence of absence 원칙에 부합합니다.

핵심: $p \geq 0.05$ = 검정력 부족. 효과 크기 $|d|=1.91$ 은 매우 큼. 시드 $n=10+$ 로 보강 예정.

주의: "통계적으로 의미 없으니 효과도 없다"로 해석하면 안 됨.

Q. Cohen's d가 -1.91 인데 음수 — 성능이 나빠졌다는 뜻 아닌가요?

아닙니다. 음수는 단순히 빼는 순서에서 나온 부호입니다.

공식: $d = (\mu_A - \mu_B) / \sigma_{\text{pooled}}$. 저희는 A_B(베이스) - D_B(개선)로 계산했고, D_B가 더 높아서 음수가 된 것입니다.

효과 크기 해석은 절댓값으로 봅니다: $|d| = 1.91$.

Cohen 1988 임계: 0.2(small) / 0.5(medium) / 0.8(large) / 1.2+(very large). 1.91은 'very large'.

핵심: 음수 = 방향, $|d|=1.91$ = 매우 큰 효과 크기.

Q. H3(맥락 학습) 가설을 사후에 "정제된 집중"으로 재해석한 것 같은데, 이건 사후 합리화 아닌가요?

정직하게 말씀드리면, 사전 가설은 "CI/IS/MSS 모두 향상"이었고 이것은 실패했습니다 — 맥락 학습 직접 지표는 통계적으로 향상되지 않았습니다.

다만 동일 모델에서 Plausibility(+22%)와 Comprehensiveness/Sufficiency(+12.7%/+11.4%)는 일관되게 향상되었습니다.

이는 "맥락이 폭넓게 분산되어 학습된 것"은 아니지만, "단어 신호에 더 정제되게 집중"한 결과로 해석 가능합니다.

이 재해석은 가설 실패를 숨기지 않고 별도 슬라이드에서 명시했고, 추후 implicit hate 데이터셋으로 진짜 맥락 학습을 검증하는 게 다음 단계입니다.

핵심: 사전 가설(맥락 학습) 실패 → 관측된 부분 성과를 "정제된 집중"으로 재해석. 한계 명시.

주의: 질문자가 압박하면 그대로 인정. "네, 사전 가설은 실패했습니다"가 정직한 답.

Q. Mathew et al. 2021 (HateXplain 원논문)과 차별점이 정확히 뭐예요?

Mathew 2021은 데이터셋 공개 + Bias/Faithfulness 분석 베이스라인 제공이 핵심이었습니다.

저희는 (1) 학습 처치(Training Intervention) 적용: Attention Loss로 모델 학습 자체에 개입.

(2) 8조건 factorial ablation: 2(Attn) × 2(VADER) × 2(BERT/RoBERTa)로 단일 변수 효과 분리.

(3) XAI 4축 12지표 자동 평가: Mathew는 SHAP/LIME 일부 지표만, 저희는 Attribution + Faithfulness + Context + Plausibility 4축을 통합.

(4) 자체 IAA 계산 + 통계 검정(ANOVA/t-test/Cohen's d) 적용으로 효과 크기 정량화.

핵심: 원논문=분석 중심. 저희=학습 처치 + 8조건 통제 + XAI 4축 + 통계 검정.

Q. "학습 처치(Training Intervention)"가 정확히 뭔가요?

Training Intervention = 모델 학습 단계에서 기존 cross-entropy 분류 손실 외에 추가 손실 항을 도입해 모델의 "보는 방식"에 직접 개입하는 것.

구체적으로 $L_{total} = L_{cls} + \alpha \cdot L_{attn} - \alpha \cdot L_{attn}$ 항이 그것입니다.

$L_{attn} = \text{BCE}(\text{CLS의 첫 layer attention 분포, 인간 rationale 마스크})$ per-token.

즉 "모델이 [CLS] 토큰을 통해 어디를 보는지"를 인간이 표시한 근거 토큰과 일치하도록 학습 시그널을 줍니다.

Mathew 2021은 이런 처치 없이 모델을 학습 후 분석만 했지만, 저희는 학습 자체에 개입한 것이 차별점.

핵심: Training Intervention = 학습 손실 함수에 직접 개입 (기존 처치 = 학습 후 분석만).

P1. 모델·방법론

Q. VADER 4차원으로 충분한가요? 더 강한 sentiment 모델 안 쓴 이유는?

VADER는 4차원(neg/neu/pos/compound)으로 매우 컴팩트하지만 SNS 도메인에 특화 (이모티콘, 약어, 강조 표현 처리).

Hutto & Gilbert 2014에서 SNS 텍스트 기준 BERT-base 수준 sentiment 정확도 보고.

추가 sentiment 모델(예: RoBERTa Sentiment) 사용도 가능하지만 그 자체가 transformer라 "VADER vs Transformer 단독 추가"의 변수 분리가 어려워집니다.

본 실험은 "가장 단순한 외부 sentiment 신호 추가의 효과"를 깨끗이 측정하는 것이 목표여서 VADER가 적절했습니다.

핵심: VADER 선택은 "단순 + 도메인 특화 + 변수 통제" 목적.

Q. Attention Loss는 정확히 어떻게 작동하나요?

1) Forward 시 BERT 첫 번째 layer의 [CLS] 토큰이 모든 토큰에 대해 가지는 attention 분포를 추출.

2) HateXplain의 인간 rationale 마스크(혐오 근거 토큰 = 1, 나머지 = 0)와 비교.

3) BCE(Binary Cross Entropy) per-token loss로 두 분포를 일치시킴.

4) 최종 손실: $L_{total} = L_{cls} + \alpha \cdot L_{attn}$ (α 는 그리드서치로 1.0 결정).

직관: "모델이 CLS로 정보를 모을 때, 인간이 표시한 근거 토큰을 우선적으로 보도록 유도".

핵심: 첫 layer [CLS] attention을 인간 rationale에 BCE로 일치시키는 토큰 단위 보조 손실.

주의: "왜 첫 layer?" — 입력 단어 정보가 아직 raw 형태로 남아있어 토큰별 정렬이 가장 명확.

Q. $\alpha=1.0$ 은 어떻게 결정했나요? 그리드서치 했나요?

예, B_B 조건에서 $\alpha \in \{0.0, 0.1, 0.3, 0.5, 0.7, 1.0\}$ 그리드로 검증했습니다.

검증 셋 Macro F1 기준 $\alpha=1.0$ 이 최고(0.6665)였고, 0.7과 비슷하지만 일관성 있게 $\alpha=1.0$ 이 우세.

결정된 $\alpha=1.0$ 을 D_B/B_R/D_R 모든 attention 사용 조건에 동일 적용 → 변수 통제.

각 조건마다 별도 그리드서치를 하면 "조건 간 비교 가능성"이 깨지기 때문에 단일 α 정책.

핵심: B_B에서 $\alpha=1.0$ 결정 후 4개 attention 조건에 동일 적용 (변수 통제).

Q. 왜 D_B 부가 실험에만 듀얼 헤드를 사용했나요?

L_{target} (타깃 그룹 분류 보조 헤드)은 main ablation의 단일 변수 통제 원칙을 깨뜨려 메인 매트릭스에서 제외.

D_B(BERT + Attn + VADER, 가장 풍부한 조건)에서만 부가 실험으로 듀얼 헤드(Main 분류 + Aux target) 적용.

결과: β grid 결과 분석 중 — 발표 시점에는 "Phase 3 예정"으로 보고.

메인 결론은 8조건 ablation에 두고, L_{target} 은 별도 부가 실험으로 분리한 이유.

핵심: L_{target} 은 main 매트릭스 외부 부가 실험. D_B에서만 적용. 변수 통제 보존.

Q. Freeze Study는 왜 BERT만 했나요?

Transfer Learning 방식의 효과(Frozen vs Full FT)를 "확실하게 보이는 통제군"으로만 검증하면 충분하다고 판단.

BERT만으로 Frozen 0.401 vs Full FT 0.681 (+28%p) 효과를 명확히 입증.

RoBERTa도 동일 경향이 예상되며, 본 실험의 메인 변수는 Attn/VADER이지 동결 방식이 아니므로 BERT 한 번으로 통제 충분.

리소스 제약 + 메인 메시지에 집중하기 위한 의도적 선택.

핵심: Freeze Study는 부가 통제 검증. 메인 변수가 아니라 BERT 한 번으로 충분.

Q. 분류 헤드를 768→256→3 MLP로 통일한 이유는?

헤드 구조 차이가 성능 차이의 교란 변수가 되지 않도록 통일.

VADER 사용 조건은 768+4=772→256→3, 미사용은 768→256→3 — 입력 차원만 다르고 구조 동일.

단순 Linear(768→3) 대비 MLP가 비선형성 도입으로 약간 안정. 단 너무 깊으면 transformer 자체 학습이 묻혀서 1 hidden layer로 한정.

핵심: 모든 transformer 조건 동일 헤드 (768→256→3, VADER 시 772→256→3) — 변수 통제.

P2. 데이터·실험 설계

Q. IAA Label 0.814 vs Rationale 0.31 — 차이가 너무 큰 거 아니가요?

이 차이가 본 연구의 핵심 동기 중 하나입니다.

Label IAA 0.814: "이 문장이 hate/offensive/normal인가?" — 문장 단위 합의는 매우 높음.

Rationale IAA 0.31: "어떤 토큰이 근거인가?" — 토큰 단위 합의는 자연 상한 자체가 낮음.

이는 "인간끼리도 근거 위치는 의견이 갈린다"는 사실을 보여주며, Plausibility 평가의 상한선을 설정하는 의미를 가집니다.

저희 D_B 모델 Token F1 ≈ 0.22 는 인간 합의 0.31에 접근한 것이고, 0.31을 넘는 것은 인간 합의 자체의 한계로 의미 없을 수 있음.

핵심: 라벨은 합의 쉬움(0.81), 근거 위치는 합의 어려움(0.31). 후자가 Plausibility 상한.

Q. Stratified split 70/10/20에 seed=42 — 다른 split으로 검증했나요?

Stratified split의 시드 변동 검증은 향후 과제입니다 — 현재는 seed=42 단일 split.

다만 "학습 시드"는 {42, 52, 62} 3개로 변동 측정 → benchmark_summary.csv에 평균/표준편차 보고.

Split 시드 변동까지 보면 분산 추정치 더 안정되며, n=10 이상 split-seed 조합으로 향후 확장 예정.

핵심: Split seed=42 고정, 학습 seed {42,52,62} 3개로 변동 측정. Split seed 변동은 추후.

Q. Class imbalance (hate 30.9% / offensive 28.5% / normal 40.6%) 어떻게 처리했나요?

Stratified split으로 각 split 내 클래스 비율을 원본과 동일하게 유지.

추가 oversampling/undersampling 없이 원본 분포 학습.

평가는 Macro F1을 주 지표로 사용 — 클래스 평균을 동일 가중치로 보기 때문에 imbalance 영향 완화.

추가로 클래스별 F1, Confusion Matrix도 보고하여 특정 클래스 편향 여부 확인.

핵심: Macro F1 + Stratified split으로 imbalance 영향 완화. 추가 sampling 없음.

Q. 왜 시드를 3개만 썼나요? 더 많이 안 한 이유는?

리소스 제약 — 8조건 × 3시드 = 24 학습 + 튜닝 + freeze study + XAI 평가까지 합쳐 단일 GPU(M3 Max)에서 수십 시간.

ANOVA의 검정력 부족이 이 결정의 직접적 한계로 드러났고, 추후 시드 10개 이상 보강이 명시된 향후 과제.

현재는 효과 크기(Cohen's d)로 보완 보고.

핵심: 리소스 제약 — 시드 n=3. ANOVA 검정력 부족이 한계로 드러남.

P3. XAI 분석

Q. SHAP, LIME, LOO를 모두 쓴 이유는? 하나로 충분하지 않나요?

세 방법 모두 단점이 다르므로 교차 검증을 위해 같이 사용.

SHAP: Shapley 값 기반 모든 토큰 조합 평균 기여도, 이론적 견고하지만 계산 비싸고 transformer에는 PartitionExplainer 쓰면 워드 단위 집계 필요.

LIME: 로컬 선형 근사, 빠르고 해석 직관적이지만 무작위 perturbation 의존.

LOO (Leave-One-Out): 토큰 하나씩 제거 시 logit 변화 — 가장 단순/직관적이지만 inter-token interaction 무시.

세 방법 모두 동일 토큰을 "가장 중요"로 지목하면 신뢰성 ↑ — 본 실험에서 D_B는 세 지표 모두에서 일관되게 인간 rationale 토큰을 우선 지목.

핵심: 단일 방법 의존 ≠ 견고함. SHAP/LIME/LOO 교차 검증으로 결론 안정성 확보.

Q. CI / IS / MSS 각각이 정확히 뭐죠?

CI (Context Index, Gini 1912 원리): 토큰 중요도 분포의 불평등도. 1에 가까울수록 "한두 토큰에 집중", 0에 가까울수록 "고르게 분산(=맥락 분산)".

IS (Interaction Strength, Sundararajan 2020 영감): 토큰 간 상호작용의 강도. 높을수록 단어 단독이 아닌 "단어 조합 = 맥락"의 중요도가 큼.

MSS (Minimum Sufficient Subset): 같은 예측을 유지하기 위해 필요한 최소 토큰 비율. 작을수록 "적은 토큰만으로 결정 = 단어 의존", 클수록 "많은 토큰 필요 = 맥락 활용".

본 실험: 세 지표 모두 D_B와 A_B의 통계적으로 유의한 차이를 못 보임 (사전 가설 실패).

핵심: CI(불평등) / IS(상호작용) / MSS(최소 충분 부분집합) — 모두 "맥락 학습" 직접 지표.

주의: 이 셋이 본 실험의 사전 가설 실패 영역. 정직하게 인정해야 함.

Q. Plausibility Token F1은 어떻게 계산하나요?

1) 모델의 token attribution(SHAP/LIME 평균)을 상위 K개로 이진화 → 모델 rationale 마스크.

2) 인간 annotator가 표시한 토큰 마스크(여러 명 평균/투표)와 토큰 단위 F1 계산.

3) 모든 테스트 샘플 평균.

직관: "모델이 본 곳"과 "인간이 본 곳"이 토큰 단위로 얼마나 일치하는가.

핵심: 모델 attribution top-K vs 인간 rationale → 토큰 F1.

Q. Attention Rollout은 왜 추가했나요?

Abnar & Zuidema 2020 — 단일 layer attention은 후속 layer를 거치며 "섞이기" 때문에 한 layer만 보면 모델의 진짜 정보 흐름을 놓침.

Rollout: 모든 layer attention의 cumulative product로 "입력에서 [CLS]까지 정보가 어떻게 흘렀는가" 추적.

Attention Loss는 첫 layer 정렬을 학습 시그널로 주지만, Rollout은 학습 후 "전체 layer 통합 attention"을 사후 검증.

본 실험: D_B의 Rollout 분포가 인간 rationale에 더 정렬됨 → Attention Loss가 첫 layer뿐 아니라 layer 누적 정보 흐름까지 영향.

핵심: 단일 layer 한계를 layer 통합으로 보완. 학습(첫 layer) vs 검증(전체 layer).

P4. 서술·해석·논리

Q. "단어 + 맥락 함께 학습" 메시지의 근거가 정확히 뭐죠?

- 1) 베이스 A_B는 단어(슬러)에 강하게 의존하지만 맥락 단서를 거의 못 봄 — 이는 SHAP/LIME 분석에서 단어 토큰이 거의 모든 attribution을 차지하는 것으로 확인.
- 2) D_B는 동일한 단어 신호를 유지하면서 맥락 단서(VADER + Attention 정렬)를 추가 학습 — 단어 신호가 사라진 게 아니라 추가됨.
- 3) 결과: 분류 성능(+0.94 $\Delta F1$) + Plausibility(+22%) + Comprehensiveness/Sufficiency 모두 일관 향상. 단어 vs 맥락 이분법이 아니라 "단어 신호 위에 맥락 단서가 더해진" 모델 — 이것이 본 실험의 척추 메시지.

핵심: 단어 OR 맥락이 아니라 단어 AND 맥락. "단어 신호 유지 + 맥락 추가".

주의: "혐오는 단어가 아닌 맥락"으로 말하면 절대 안 됨 — 이분법 과장.

Q. "베이스의 단어 과의존"을 어떻게 진단했나요?

- 1) SHAP/LIME 분석에서 A_B의 attribution이 슬러 토큰 1~2개에 90%+ 집중되는 패턴 확인.
 - 2) MSS(최소 충분 부분집합)가 매우 작음 — 1~2개 토큰만 있으면 같은 예측 유지.
 - 3) Slur-Free 케이스에서 분류 정확도 0% — 슬러 없으면 못 잡음.
- 이 세 가지 증거로 "베이스는 슬러 단어 자체에 과의존하고 맥락은 거의 못 봄"이라고 진단.

핵심: SHAP attribution 집중 + 작은 MSS + Slur-Free 0%. 3가지 증거 누적.

Q. "인간 정의 카테고리 비의존 자동 XAI"라고 했는데, Plausibility는 인간 rationale 쓰지 않나요?

정확한 지적입니다 — XAI 4축 중 4번째(Plausibility)는 인간 rationale에 의존합니다.

비의존 자동 평가는 3번째 축(Context Learning: CI/IS/MSS)에 한정됩니다.

1축(Attribution: SHAP/LIME/LOO)과 2축(Faithfulness: Comp/Suff)은 모델 출력 변화로만 계산되어 인간 라벨링 비의존.

발표 슬라이드에서는 "4축 중 3축(Attribution/Faithfulness/Context)이 인간 라벨 없이 자동 평가, Plausibility는 인간 비교 검증용"으로 정확히 기술해야 함.

핵심: 비의존 자동 = Attribution + Faithfulness + Context (3축). Plausibility는 인간 비교용.

주의: "4축 모두 인간 비의존"은 과장. 정확하게는 "3축 + 1축 인간 비교".

Q. 결국 우리의 "맥락 학습" 가설은 실패한 건가요?

사전 가설 (CI/IS/MSS 직접 향상)은 통계적으로 미달 — 실패라고 인정해야 합니다.

다만 부분 성과는 명확함: Plausibility +22%, Comprehensiveness +12.7%, Sufficiency +11.4% 모두 일관 향상.

재해석: "맥락이 폭넓게 분산되어 학습"이 아니라 "단어 신호에 더 정제되게 집중".

다음 단계: implicit hate 데이터셋(슬러 없는 혐오)으로 재검증 — 이때 진짜 맥락 학습 여부 측정 가능.

핵심: 사전 가설 실패 → 관측 부분 성과를 "정제된 집중"으로 재해석. 다음 단계는 implicit hate 검증.

Q. 향후 과제는 뭔가요?

- 1) 시드 n=10+ 보강으로 ANOVA 검정력 확보.
- 2) Implicit hate 데이터셋(슬러 없는 혐오) 추가 검증 — 진짜 맥락 학습 여부.
- 3) $\beta \cdot L_{\text{target}}$ 그리드 분석 마무리 (Phase 3).
- 4) Cross-domain 일반화 (다른 SNS 플랫폼/언어).
- 5) Bias 분석 (인종/성별/종교 그룹별 false positive rate).

핵심: 시드 보강 + implicit hate 검증 + β 그리드 + cross-domain + bias 분석.

P5. 기술 디테일

Q. input_ids, attention_mask가 정확히 뭐죠?

input_ids: 텍스트를 토큰라이저로 잘게 쪼개 각 서브워드를 vocabulary의 정수 ID로 매핑한 시퀀스. (예: "hello" → [7592])

attention_mask: 어떤 위치가 실제 토큰이고 어떤 위치가 패딩인지 1/0으로 표시. 길이 다른 문장을 배치 처리하려면 짧은 문장에 padding을 채우는데, 모델이 padding을 무시하도록 mask=0.

둘 다 transformer 입력의 표준 형식.

핵심: input_ids = 토큰 ID 시퀀스, attention_mask = 패딩 무시용 마스크.

Q. vocab 30,522개로 모든 영어 단어를 커버하나요?

아닙니다. 영어 단어는 수십만 개 이상이라 30,522로 모두 못 담음.

WordPiece(BERT)/BPE(RoBERTa)는 "서브워드" 단위로 쪼갬: 흔한 단어는 통째로, 흔하지 않은 단어는 더 작은 조각으로 분해.

예: "unhappiness" → ["un", "##happi", "##ness"]. ##는 "앞 토큰에 붙는 조각"이라는 표시.

이 방식으로 30K vocab으로도 사실상 모든 영어 단어 표현 가능.

핵심: 서브워드 토큰라이저로 30K vocab도 무한 단어 커버. ##(BERT)/(RoBERTa)는 결합 표시.

Q. 사전학습(Pre-training)과 파인튜닝(Fine-tuning) 차이는?

Pre-training: 대량 일반 텍스트(BookCorpus + Wikipedia 등 수십 GB)로 self-supervised(MLM 등) 학습. 언어의 일반 패턴 학습. → BERT 가중치는 이미 사전학습된 상태로 공개됨.

Fine-tuning: 특정 task의 작은 라벨 데이터(예: HateXplain 19K)로 모델 가중치를 살짝 조정. 일반 언어 지식을 task에 특화.

본 실험은 Pre-training 단계는 사용 (HuggingFace 공개 가중치), Fine-tuning만 직접 수행.

핵심: Pre-training=대량 일반 학습(공개 가중치 사용), Fine-tuning=task 특화 미세조정.

Q. 학습 데이터 입력/출력과 실제 추론 입력/출력 구조는?

학습 데이터 입력: post_tokens (텍스트), 라벨, rationale 마스크 (Attn 사용 시), VADER 4d (VADER 사용 시).

학습 데이터 출력 (모델 예측): 3-class logits (hate/offensive/normal).

학습 손실 = 분류 + Attention 정렬 + (D_B만) Target 보조

추론(실제) 입력: 텍스트 한 문장.

추론 출력: 3-class 확률 + (XAI용 후처리) attribution 점수.

rationale은 학습 supervision으로만 사용, 추론 시 입력 X. VADER는 추론 시 자동 계산.

핵심: 학습=텍스트+라벨+rationale (supervision). 추론=텍스트만 (rationale 입력 X, VADER 자동).

Q. BERT WordPiece(##)와 RoBERTa BPE()의 차이는?

BERT WordPiece: "##"가 "앞 토큰에 이어 붙는 조각" 표시. 예: "playing" → ["play", "##ing"].

RoBERTa BPE: " "(공백 표시 문자)가 "새 단어 시작" 표시. 예: "playing" → [" play", "ing"]. 공백 단위로 다름.

둘 다 서브워드 토큰나이저지만 슬러 같은 OOV 단어 처리 패턴이 미세하게 다름 → BERT가 슬러를 통째로 보존하기 더 쉬워 본 실험에서 약간 유리.

핵심: ## (BERT, 이어붙는 조각) vs (RoBERTa, 새 단어 시작 공백). 슬러 보존성 차이.

P6. 비교·차별점

Q. Cheng 2022 (Virginia Tech)와 차별점이 뭔가요?

Cheng 2022: VADER + transformer로 SNS 혐오 탐지 — 본 실험의 VADER 통합 영감의 출처.

차이 (1): Cheng은 분석 중심(post-hoc), 저희는 학습 처치(Attention Loss로 학습 자체 개입).

차이 (2): Cheng은 단일 모델, 저희는 8조건 factorial ablation으로 단일 변수 효과 분리.

차이 (3): Cheng의 XAI는 attention visualization, 저희는 4축 12지표 자동 평가.

차이 (4): 저희는 통계 검정(ANOVA/t-test/Cohen's d) 추가.

핵심: Cheng=VADER+post-hoc, 저희=VADER+학습 처치+factorial ablation+XAI 4축+통계 검정.

Q. 다른 팀(찹쌀떡, 판다님, F조, 오남)과의 차별점은?

찹쌀떡/판다님/오남: 일반 분류 성능 중심, XAI 분석 부재 또는 단일 지표.

F조: 데이터 분석 중심.

본 팀 차별점:

(1) 8조건 factorial ablation으로 변수 효과 분리.

(2) XAI 4축 12지표 통합 평가 (Attribution + Faithfulness + Context + Plausibility).

(3) 자체 IAA 계산 + 통계 검정으로 효과 크기 정량화.

(4) Training Intervention 기반 학습 처치 (분석이 아닌 학습 자체 개입).

핵심: 다른 팀=분류 중심. 본 팀=분류+XAI 4축+통계 검정+학습 처치 통합.

부록. 숫자 치트시트

자주 묻는 숫자들 — 발표 중 즉답용

항목	값	출처
데이터 총 샘플	19,192건	HateXplain (Mathew 2021)
클래스 분포	hate 30.9% / offensive 28.5% / normal 40.6%	benchmark_summary.json
Split	70/10/20 (Stratified, seed=42)	experiment_core
학습 시드	{42, 52, 62} (n=3)	experiment_core
Label IAA	0.814	Mathew 2021 / 자체 검증
Rationale IAA	0.31 (자체 계산)	11,412 샘플 LOO
Optimizer	AdamW + linear warmup	experiment_core
Learning rate	2e-5 (1e-5~3e-5 그리드)	tuning
Batch size	64	experiment_core
Best α (Attention loss)	1.0	B_B 그리드서치
Best β (L_target)	Phase 3 예정	분석 진행 중
Vocab size	BERT 30,522 / RoBERTa 50,265	HuggingFace
Hidden dim	768	BERT/RoBERTa base
분류 헤드	768→256→3 (VADER 시 772→256→3)	experiment_core
Macro F1 A_B (베이스)	0.6791	benchmark_summary.csv
Macro F1 D_B (개선)	0.6885	benchmark_summary.csv
$\Delta F1$ (D_B - A_B)	+0.94 (+0.0094)	계산
Cohen's d (A_B vs D_B)	-1.91 (d =1.91, very large)	significance_tests.csv
ANOVA p (Attn 주효과)	0.518	anova_2way_bert.csv
ANOVA p (VADER 주효과)	0.961	anova_2way_bert.csv
ANOVA p (교호작용)	0.470	anova_2way_bert.csv
Plausibility Token F1 A_B	≈ 0.18	XAI 결과
Plausibility Token F1 D_B	≈ 0.22 (+22%)	XAI 결과
Comprehensiveness 향상	+12.7%	XAI 결과
Sufficiency 향상	+11.4%	XAI 결과
Freeze (Frozen) Macro F1	0.401	freeze_study.csv
Freeze (Full FT) Macro F1	0.681	freeze_study.csv
Freeze 효과	+28%p	계산
Slur-Free 정확도	0% (베이스/개선 동일)	한계 분석

발표 답변 원칙

1. 정직 우선

한계는 숨기지 말고 그대로 인정. "네, 그 부분은 한계입니다"는 점수 깎는 표현이 아니라 신뢰 점수.

2. 단어 vs 맥락 이분법 절대 금지

"혐오는 단어가 아닌 맥락" → X. "단어 단서뿐 아니라 맥락 단서까지 함께 학습" → O.

3. 사전 가설 실패 인정

CI/IS/MSS는 통계적으로 항상 못 함. 이건 사실대로. 대신 부분 성과(Plausibility/Comp/Suff)를 "정제된 집중"으로 재해석.

4. 통계 vs 효과 크기 분리

ANOVA 미달 = 검정력 부족(시드 n=3). Cohen's d |1.91| = 효과 크기 매우 큼. 둘은 다른 정보.

5. Slur-Free 한계는 솔직하게

"슬러 없으면 못 잡습니다. 이게 다음 단계(implicit hate) 출발점입니다."

6. 베이스 단어 신호 부정 X

베이스 문제는 "단어 의존"이 아니라 "단어 *과*의존". 단어 자체가 신호가 아닌 건 아님.

7. 본 연구 = 분석 + 학습 처치

Mathew 2021/Cheng 2022 = 분석 중심. 본 연구 = 학습 손실 함수에 직접 개입(Training Intervention).

8. 4축 비의존 자동 정확히

Attribution + Faithfulness + Context = 인간 라벨 비의존 자동. Plausibility = 인간 비교용. "4축 모두 비의존"은 과장.