

빅데이터프로그래밍 산학협력프로젝트 수행계획서

과제 수행원 현황						
수행 학기	2026학년도 1학기					
프로젝트명	맥락 이해 기반 혐오표현 탐지 개선					
팀명	올에이프로젝트					
구분	이름	학번	소속		전화번호	이메일
			1트랙	2트랙		
팀장	정수현	2171441	빅데이터 트랙	모바일 소프트웨어 트랙	010-4047-9910	winterflw@hansung.ac.kr
팀원	김정훈	2071265	웹공학 트랙	빅데이터 트랙	010-3829-6128	jhtree01@hansung.ac.kr
	박종화	2171543	산업공학 트랙	빅데이터 트랙	010-5570-8620	jong8620@naver.com
	조은	2271436	빅데이터 트랙	웹공학 트랙	010-2023-0812	whdms@hansung.ac.kr
	차종민	2171159	빅데이터 트랙	모바일 소프트웨어 트랙	010-56882933	jongmin881@naver.com
지도교수	교과목명		빅데이터프로그래밍		과목코드	V022005
	성명		이청용			
	소속		컴퓨터공학부			
산업체 멘토	기업명		왓차			
	멘토 성명		임해빈	멘토 직위	매니저(ML팀)	

프로젝트 수행계획서	
프로젝트 개요	제목 : 맥락 이해 기반 혐오표현 탐지 개선: Rationale-aware Attention Loss와 XAI 3축 검증 목표 : 선행연구 기반 가설 수립 → 통제된 ablation 실험 → XAI 사후 검증의 과학적 검증 프레임워크를 설계 및 구현하여, 혐오표현 탐지 모델의 분류 성능과 판단 투명성을 동시에 향상시키는 것이 목적이다.

추진 배경	배경: - 온라인 혐오표현은 특정 집단에 대한 적대감을 조성하고, 실제 혐오 범죄로 이어질 수 있는 심각한 사회문제이다. 주요 소셜 플랫폼은 자동 탐지 시스템을 도입하고 있으나, 기존 모델 중 일부는 비하어(slur) 출현 여부에 과도하게 의존하여 맥락에 따라 의미가 달라지는 표현을 오분류하는 한계가 있다. - 모델이 "왜 그렇게 판단했는가"를 설명하지 못하면, 오탐 사례에 대한 원인 파악과 체계적 개선이 불가능하며, 콘텐츠 모더레이션 현장에서의 신뢰 확보도 어렵다. 필요성: - 유럽연합 디지털서비스법(DSA, 2024 시행), 한국 방송통신심의위원회의 자동 필터링 권고 등 규제 환경이 강화되면서, 탐지 정확도뿐 아니라 판단 근거의 투명성까지 요구되는 추세이다. - BERT 기반 혐오표현 탐지는 학계·산업 양쪽에서 활발히 연구되고 있으나, XAI를 통해 개선 효과를 정량 검증하는 연구는 아직 부족하다. 선행사례: Mathew et al. (2021)— HateXplain 데이터셋과 함께 인간 rationale 기반 평가를 제안했으나, rationale 정보를 학습 과정에 직접 반영하지는 않았다. Cheng (2022, Virginia Tech)— BERT에 SHAP·LIME을 적용해 혐오표현 오분류 패턴을 분석했으나, 진단 결과를 모델 개선으로 연결하지 못하고 분석 단계에 머물렀다. - 본 프로젝트는 이 두 연구의 한계를 결합하여, rationale 정보를 Attention Loss로 학습에 반영하고 그 효과를 XAI 3축으로 검증하는 데까지 나아간다.
목표 및 내용	개발목표: - 인간 어노테이터의 판단 근거(rationale)를 학습에 직접 반영하여, 단순 정답 레이블 학습을 넘어 "왜 혐오인가"의 근거까지 학습하는 Rationale-aware 혐오표현 탐지 파이프라인 - Attention Loss와 Slur-Masking Augmentation 두 개선 기법의 독립 효과와 상호작용을 통제된 조건에서 분리 측정하는 2×2 ablation 실험 체계(4조건 × 6모델) - SHAP × LIME × Masking 3축 XAI 분석으로 개선 전후를 정량 비교하고, 성능 향상의 원인을 설명 가능한 형태로 제시하는 검증 보고서 개발내용: 1. 데이터 파이프라인 구축 HateXplain 데이터셋(20,148건, 필터링 후 19,192건)은 각 게시글에 3인 어노테이터가 독립적으로 레이블(hatespeech/offensive/normal)과 rationale(근거 토큰 위치)을 표기한 구조이다. 3인의 rationale을 다수결 투표(≥2인 선택)로 통합하여 이진 마스크를 구성하고, BERT-RoBERTa 토큰라이저가 생성하는 서브워드 토큰과 원문 단어 간 인덱스 매핑 및 점수 합산(aggregation)을 수행하여 모델

	입력 형태로 정제한다. normal 클래스(7,789건)는 rationale이 존재하지 않으므로 Attention Loss 적용 대상에서 제외한다. 2. Slur-Masking Augmentation CrossEntropy만으로 학습하면 모델은 특정 비하어의 출현 여부만으로 판단하는 shortcut을 학습하게 된다. 이를 완화하기 위해 hate-offensive 샘플(11,403건)에서 사전 정의된 비하어 목록(약 51개)에 해당하는 토큰을 확률 $p=0.3$으로 [MASK]로 치환한 증강 데이터셋을 생성한다. 원본과 증강본을 결합하여 학습함으로써, 모델이 비하어 유무가 아닌 주변 문맥과 문장 구조에 기반하여 혐오 여부를 판단하도록 유도한다. 3. 모델 학습 및 Attention Loss 적용 베이스 라인 2개(TF-IDF+Logistic Regression, TF-IDF+SVM)와 Transformer 기반 모델 4개(BERT-base, BERT+MLP, BERT+VADER, RoBERTa+VADER)를 구축한다. Transformer 모델에는 기존 분류 손실에 rationale 정렬 항을 추가한 $L_{total} = L_{cls} + \alpha \cdot L_{attn}$ 손실함수를 적용한다. L_{attn}은 CLS 토큰의 attention 분포와 인간 rationale 마스크 간 BCE(Binary Cross-Entropy)로 계산되며, α는 0.0~1.0 범위에서 그리드 서치하여 최적값을 탐색한다. 이를 통해 모델의 attention이 인간 어노테이터가 실제로 주목한 토큰에 수렴하도록 학습을 유도한다. 4. XAI 3축 검증 4조건 (A: 기본, B: Attention Loss만, C: Augmentation만, D: 둘 다 적용) 각각의 학습 완료 모델에 동일한 XAI 분석을 적용한다. SHAP은 각 토큰의 Shapley 기여도를 산출하여 분류 결정에 대한 개별 토큰의 영향력을 측정하고, LIME은 입력 단어를 섭동하여 국소적 결정 경계를 근사한다. 두 기법의 상위 5개 중요 토큰 일치도(Overlap@5)를 교차 비교하여 해석의 일관성을 검증한다. Masking 축에서는 상위 중요 토큰 제거 시 예측 변화(Comprehensiveness $\uparrow$), 상위 중요 토큰만 남겼을 때의 예측 유지(Sufficiency $\downarrow$), 비하어 마스킹 후 정분류 유지율(Slur-Free Prediction)을 측정하여, 모델이 실제로 맥락에 기반한 판단을 수행하는지를 다각도로 검증한다. 역할분담 : - 정수현 : 파이프라인 구현, XAI 데이터 분석 - 김정훈 : 데이터 전처리, 파이프라인 구현 - 박종화 : 파이프라인 설계 - 조 은 : EDA, XAI 데이터 분석 - 차종민 : 선행 논문 분석, 파이프라인 개선
기대효과	기대효과: 콘텐츠 모더레이션 현장: 혐오표현 탐지 모델이 판단 근거를 함께 제시함으로써, 모더레이터가 오탐·미탐 사례를 빠르게 검토하고 이의 제기에 근거 기반으로 대응할 수 있다. 대규모 플랫폼의 심의 효율성과 일관성을 동시에 향상시킬 수 있다. 학술적 기여: Rationale-aware Attention Loss와 Slur-Masking Augmentation의 효과를 4조건 ablation과 통계 검정으로 분리 검증하는

	방법론은, 혐오표현 탐지뿐 아니라 감성 분석·가짜뉴스 탐지 등 텍스트 분류 전반에 적용 가능한 실험 설계 템플릿을 제공한다. • 사회적 측면: 비하어 단순 매칭이 아닌 맥락 기반 판단이 가능해지면, 비하어를 포함하지만 혐오 의도가 없는 발화(인용, 교육, 재전유)의 과잉 차단을 줄일 수 있다. 이는 표현의 자유와 혐오 규제 사이의 균형점을 기술적으로 뒷받침한다. • 규제 대응: EU 디지털서비스법(DSA) 등 판단 투명성을 요구하는 규제 환경에서, XAI 기반 설명 가능성은 법적 준수 요건을 충족하는 데 실질적 근거가 된다.
--	--